

DỰ ĐOÁN NHỊP TIM BẰNG PHƯƠNG PHÁP HỌC SÂU

Đỗ Thanh Nghị, Võ Trí Thức

Khoa Công nghệ thông tin và Truyền thông, Trường Đại học Cần Thơ

dtnghe@cit.ctu.edu.vn, vtthuc@ctu.edu.vn

TÓM TẮT: Trong bài báo này, chúng tôi đề xuất hệ thống dự đoán nhịp tim bằng các phương pháp học sâu. Bệnh lý tim mạch là một trong những bệnh nguy hiểm, khiến người bệnh có nguy cơ tử vong rất cao và nhanh. Theo dõi và dự đoán nhịp tim vì thế có vai trò quan trọng để phát hiện sớm sự bất thường chức năng của tim, xử lý kịp thời, tránh được nguy cơ tử vong. Để giải quyết vấn đề này, chúng tôi đã phát triển hệ thống dự đoán nhịp tim dựa trên 6 mô hình học sâu phổ biến như Gated recurrent units (GRU), Long short-term memory (LSTM), Bidirectional gated recurrent units (Bi-GRU), Bidirectional long short-term memory (Bi-LSTM), Convolutional neural network long short-term memory (CNN-LSTM), Convolutional long short-term memory (CONV-LSTM). Hệ thống kết nối với vòng đeo tay thông minh MiBand 4 tự động thu thập nhịp tim, tạo tập dữ liệu huấn luyện và kiểm thử gồm 359.594 mẫu. Kết quả thực nghiệm cho thấy cả 6 mô hình có giá trị trung bình lỗi tuyệt đối (MAE) trong khoảng 3,4 đến 4,2, trong đó mô hình Bi-GRU đạt giá trị MAE thấp nhất (3.4535), tiếp theo sau là Bi-LSTM là (3.4766).

Từ khóa: Dự đoán nhịp tim, mạng học sâu, đồng hồ thông minh MiBand.

I. GIỚI THIỆU

Bệnh lý về tim là một trong những nguyên nhân gây ra tử vong cao trên thế giới bởi vì tim không thể thực hiện đúng chức năng chính là bơm máu đến các bộ phận khác để thực hiện các chức năng của nó. Nhịp tim theo y khoa định nghĩa là số lần tim đập trong một phút, chỉ số này khác nhau giữa các độ tuổi và nhịp tim của người trưởng thành trung bình từ 60 đến 100 nhịp/phút. Nhịp tim có thể bị ảnh hưởng bởi nhiều yếu tố như hoạt động thể chất, trạng thái tinh thần, giới tính, tuổi, ... Vì vậy, việc nghiên cứu nhịp tim và theo dõi sự thay đổi bất thường của nhịp tim có ý nghĩa rất lớn và đóng vai trò quan trọng theo dõi sức khỏe bệnh nhân.

Trong những năm gần đây, sự phát triển của các thiết bị vòng đeo tay và đồng hồ thông minh với sự hỗ trợ theo dõi sức khỏe đã đóng góp lớn vào ngành y tế. Các thiết bị này cho phép theo dõi liên tục theo thời gian thực bao gồm nhịp tim, số bước đi, chạy, leo bậc cầu thang, lượng calo tiêu thụ thông qua cảm biến. Công nghệ thiết bị đeo tay đóng vai trò quan trọng để sớm phát hiện những bất thường về nhịp tim đã mang lại lợi ích chăm sóc sức khỏe cũng như hạn chế nguy cơ bệnh tiến triển phức tạp. Việc chẩn đoán sớm sẽ giúp việc điều trị bệnh ở những giai đoạn đầu hiệu quả.

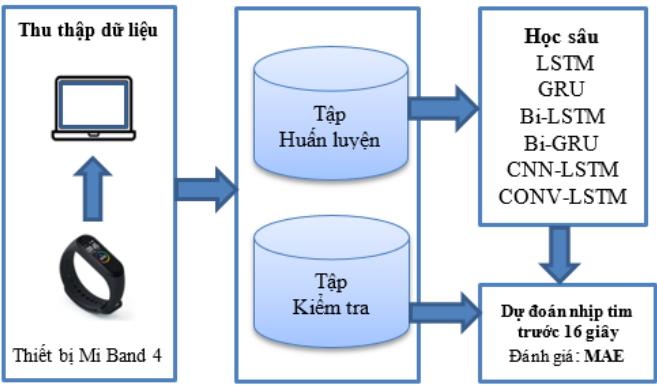
Nhiều nghiên cứu về dự đoán nhịp tim đã được thực hiện bằng cách sử dụng phương pháp máy học và học sâu. Tác giả Abdullah Alharbi cùng các cộng sự [1] đã thực hiện nghiên cứu về dự đoán nhịp tim theo thời gian thực. Dữ liệu huấn luyện từ tập dữ liệu Information Mart for Intensive Care (MIMIC-II) và được đưa qua mạng học sâu như: RNN, LSTM, GRU và Bi-LSTM. Kết quả thực nghiệm cho thấy chỉ số RMSE của GRU đạt hiệu quả tốt nhất. Trong [2], nhóm nghiên cứu đã thực hiện dự đoán nhịp tim dựa trên dữ liệu thu thập gồm có 5 thuộc tính: tín hiệu nhịp tim, giới tính, tuổi, hoạt động thể chất và trạng thái tinh thần. Kết quả cho thấy Adam-LSTM là một phương pháp tốt để dự đoán nhịp tim và phản ánh xu hướng thay đổi nhịp tim trong cuộc sống hàng ngày. Tác giả [3] đã đề xuất dự đoán nhịp tim thông qua sử dụng thiết bị đeo tay bằng phương pháp học tích cực trực tuyến để dự đoán nhịp tim của những bệnh nhân có can thiệp về van tim. Kết quả thực nghiệm đạt được cho thấy giá trị MAE là 2,89. Tác giả [4] so sánh kết quả của 3 mô hình gồm Autoregressive Model, LSTM, Convolutional LSTM cho bài toán dự đoán nhịp tim. Dữ liệu được thu thập của 12 người gồm những thông tin nhịp tim, thời gian ngủ, hoạt động thể chất thông qua thiết bị Fitbit Versa. Kết quả thực nghiệm cho thấy rằng Autoregressive Model đạt kết quả tốt nhất trong 3 mô hình với giá trị MAE là 2.069. Trong [11], nhóm tác giả Dwaipayan Biswas cùng các cộng sự đã nghiên cứu phương pháp học sâu gồm 2 tầng CNN, 2 tầng LSTM và 1 tầng Densenet để dự đoán nhịp tim từ tín hiệu PPG được sử dụng trong các xe cứu thương. Kiến trúc mạng của nhóm nghiên cứu này được đánh giá trên tập dữ liệu TROIKA gồm 22 mẫu PPG với giá trị MAE là 1.47 ± 3.37 nhịp tim trên phút. Nhóm nghiên cứu [12] đã đề xuất kiến trúc học sâu để ước lượng nhịp tim bằng tín hiệu PPG với dữ liệu đầu vào có độ dài 8 giây từ thiết bị vòng đeo cổ tay. Mô hình đề xuất được đánh giá trên tập dữ liệu IEEE SPC 2015 với giá trị MAE là $3,46 \pm 4,1$ nhịp trên phút. Tác giả [13] đã đề xuất dự đoán nhịp tim dựa trên dữ liệu nhịp tim và các hoạt động thể chất bằng phương pháp Feedforward Neural Network với giá trị MAE đánh giá mô hình trong giới hạn là 5.

Nhịp tim được dự đoán hiệu quả và đáng tin cậy có ý nghĩa rất lớn đối với việc phòng và chống những bệnh liên quan đến tim mạch. Trong bài báo này, chúng tôi đề xuất xây dựng hệ thống dự đoán nhịp tim dựa trên phương pháp học sâu. Chúng tôi tiến hành nghiên cứu bắt đầu từ việc thu thập dữ liệu nhịp tim thông qua thiết bị đồng hồ thông minh MiBand 4. Tiếp theo chúng tôi thực hiện huấn luyện với 6 mô hình học sâu để dự đoán nhịp tim bao gồm LSTM, GRU, Bi-LSTM, Bi-GRU, CNN-LSTM và CONV-LSTM. Kết quả thực nghiệm cho thấy mô hình Bi-GRU đạt hiệu quả tốt nhất khi so sánh với 5 phương pháp còn lại.

Nội dung tiếp theo của bài viết được tổ chức như sau. Phần II trình bày hệ thống dự đoán nhịp tim bao gồm kiến trúc hệ thống và 6 mô hình học sâu. Phần III trình bày phương pháp thực nghiệm và kết quả trước khi kết luận và hướng phát triển trong Phần IV.

II. HỆ THỐNG DỰ ĐOÁN NHỊP TIM

A. Mô hình hệ thống dự đoán nhịp tim



Hình 1. Mô hình dự đoán nhịp tim

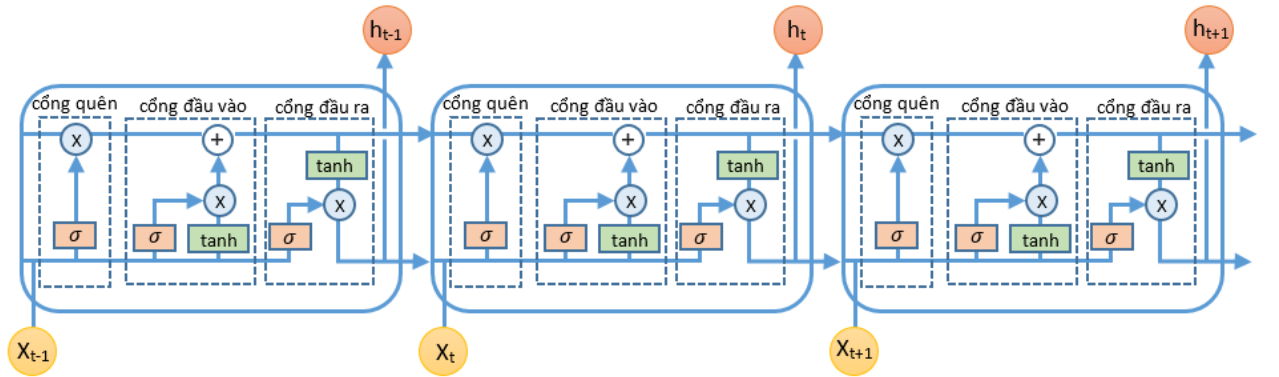
Mô hình tổng thể của hệ thống dự đoán nhịp tim bằng phương pháp học sâu được trình bày ở Hình 1 gồm có 5 bước chính: thu thập dữ liệu, tiền xử lý dữ liệu, phân chia tập dữ liệu cho huấn luyện và kiểm thử, huấn luyện mô hình bằng 6 phương pháp học sâu và đánh giá mô hình. Thu thập dữ liệu được thực hiện thông qua chương trình kết nối với thiết bị MiBand 4 thông qua Bluetooth gồm có 4 thuộc tính (nhịp tim, số bước đi, quãng đường, lượng calo tiêu thụ). Tập dữ liệu thu thập được từ 4 người được qua bước tiền xử lý để theo cửa sổ trượt là 16 giây. Kết quả thu được từ bước tiền xử lý thì chúng tôi tiến hành chia tập dữ liệu thành 2 tập gồm tập huấn luyện và tập kiểm thử để huấn luyện và đánh giá mô hình học sâu cho vấn đề dự đoán nhịp tim. Tiếp theo, 67 % tập dữ liệu được đưa qua 6 mô hình học sâu để huấn luyện mô hình. Cuối cùng, đánh giá mô hình học sâu với 33 % tập dữ liệu kiểm thử bằng chỉ số trung bình sai số tuyệt đối (MAE).

B. Long short-term memory (LSTM)

Mạng bộ nhớ dài-ngắn (Long Short Term Memory - LSTM) được giới thiệu bởi Hochreiter & Schmidhuber vào năm 1997 [5]. LSTM là một loại mạng đặc biệt của mạng hồi quy Recurrent Neural Network (RNN) nó có khả năng học được những phụ thuộc xa. Mạng LSTM đặc biệt thích hợp cho các vấn đề dự đoán trình tự theo chuỗi thời gian. Kiến trúc của LSTM bao gồm một tập hợp các ô (cell) được kết nối lại với nhau. Mỗi ô gồm có 3 cổng: cổng quên (thông tin nào cần loại bỏ), cổng đầu vào (quyết định xem thông tin nào từ đầu vào được sử dụng để cập nhật trạng thái bộ nhớ), cổng đầu ra (giá trị đầu ra). Kiến trúc của LSTM được trình bày trong Hình 2. Các phương trình của một ô LSTM tại một thời điểm t như sau:

$$i_t = \sigma(W_{xi}x_t + W_{hi}h_{t-1} + W_{ci} \circ c_{t-1} + b_i)$$
$$f_t = \sigma(W_{xf}x_t + W_{hf}h_{t-1} + W_{cf} \circ c_{t-1} + b_f)$$
$$c_t = f_t \circ c_{t-1} + i_t \circ \tanh(W_{xc} * x_t + W_{hc} * h_{t-1} + b_c)$$
$$o_t = \sigma(W_{xo}x_t + W_{ho}h_{t-1} + W_{co} \circ c_t + b_o)$$
$$h_t = o_t \circ \tanh(c_t)$$

trong đó: i_t : cổng đầu vào, f_t : cổng quên, o_t : cổng đầu ra, c_t : trạng thái ô, h_t : trạng thái ẩn
W: ma trận trọng số, b: bias.



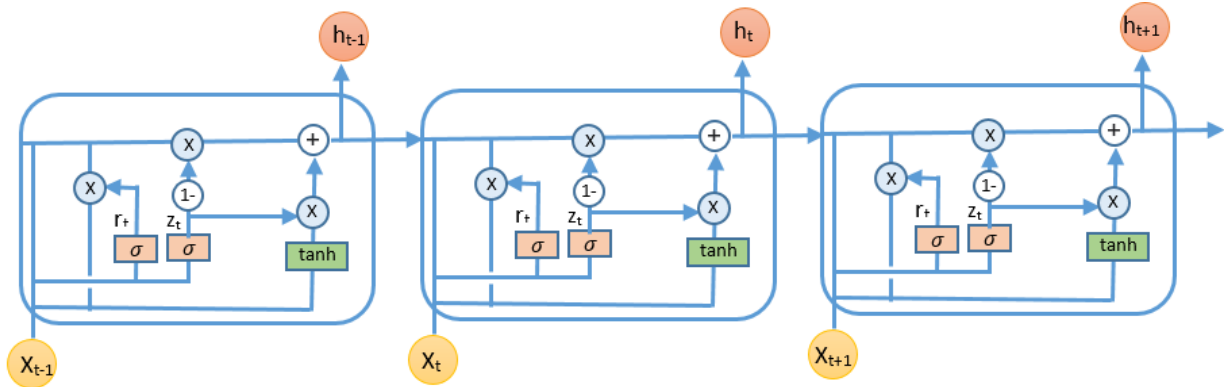
Hình 2. Kiến trúc của mạng LSTM

C. Gated recurrent units (GRU)

Mạng GRU [6] được đề xuất bởi Kyunghyun Cho cùng các cộng sự vào năm 2014. Kiến trúc mạng GRU cũng là một loại đặc biệt của RNN và có kiến trúc khá giống với LSTM. GRU là một dãy các ô được liên kết với nhau, trong đó mỗi ô trong GRU có 2 cổng: cổng cập nhật (update gate) và cổng xóa (reset gate). Cổng cập nhật sẽ quyết định có bao nhiêu thông tin trạng thái trước được cập nhật trạng thái mới trong khi đó cổng xóa sẽ quyết định xem trạng thái ẩn trước đó có bị bỏ qua hay không. So với kiến trúc LSTM thì GRU có ít hơn 1 cổng và một ưu điểm của GRU là giảm số lượng tham số so với mạng LSTM. Kiến trúc GRU được trình bày trong Hình 3. Các phương trình chính của GRU tại thời điểm t:

$$\begin{aligned} z_t &= \sigma(W_{xz}x_t + W_{hz}h_{t-1} + b_z) \\ r_t &= \sigma(W_{xr}x_t + W_{hr}h_{t-1} + b_r) \\ \tilde{h}_t &= \tanh(W_{xh}x_t + W_{hh}(r_t \odot h_{t-1}) + b_h) \\ h_t &= z_t \odot h_{t-1} + (1 - z_t) \odot \tilde{h}_t \end{aligned}$$

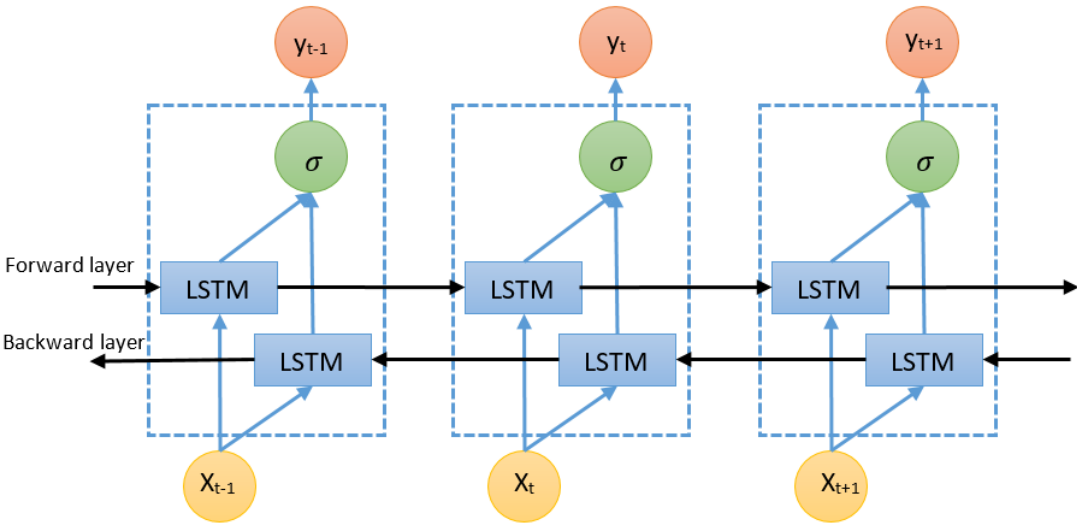
trong đó: z_t = cổng cập nhật; r_t = cổng xóa; \tilde{h}_t = trạng thái ẩn tiềm năng; h_t = trạng thái tại thời điểm t
W, b là các tham số của ma trận.



Hình 3. Kiến trúc của mạng GRU

D. Bidirectional long short-term memory (Bi-LSTM)

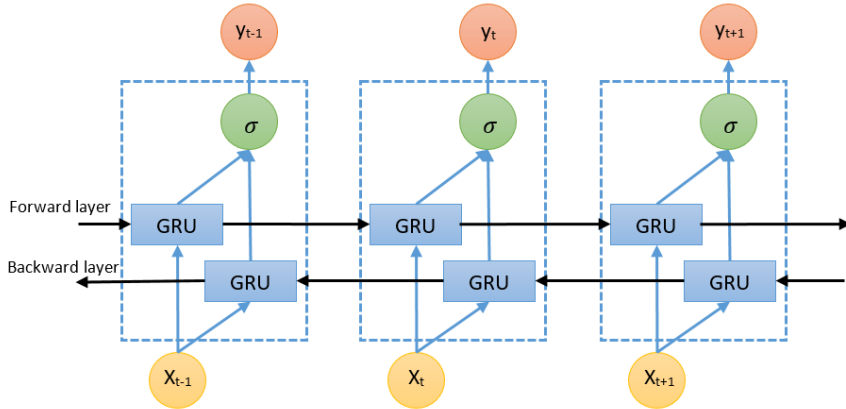
Kiến trúc Bi-LSTM đến từ ý tưởng mạng hồi quy hai chiều (Bidirectional RNN) [7] dùng để xử lý dữ liệu trình tự theo cả hai chiều là chiều xuôi (forward) và chiều ngược (backward). Nghĩa là với kiến trúc mạng hồi quy hai chiều thì thông tin dự đoán tại thời điểm t được tổng hợp thông tin từ chiều xuôi và chiều ngược. LSTM là một kiến trúc đặc biệt của RNN vì vậy có thể áp dụng LSTM theo mô hình Bi-RNN, trong đó mỗi đơn vị của RNN lúc bấy giờ tương ứng LSTM. Trong đó bao gồm có cổng quên, cổng đầu vào và cổng đầu ra. Kiến trúc của Bi-LSTM bao gồm 1 LSTM theo chiều xuôi và 1 LSTM chiều ngược được minh họa theo Hình 4.



Hình 4. Kiến trúc của mạng Bi-LSTM

E. Bidirectional gated recurrent units(Bi-GRU)


Kiến trúc Bi-GRU cũng đến từ ý tưởng mạng hồi quy hai chiều (Bidirectional RNN) [7]. Tương tự như Bi-LSTM thì cả hai chiều của Bi-GRU có thành phần tương ứng GRU. Trong đó bao gồm có 2 cổng là cổng cập nhật và cổng xóa. Kiến trúc của Bi-GRU được minh họa theo Hình 5.



Hình 5. Kiến trúc của mạng Bi-GRU

F. Convolutional neural network long short-term memory (CNN-LSTM)

Kiến trúc mạng CNN-LSTM là sự kết hợp của convolutional neural network (CNN) để trích đặc trưng và kết hợp với các LSTM để hỗ trợ dự đoán. CNN LSTM được phát triển và ứng dụng cho các bài toán liên quan dự đoán theo chuỗi thời gian trực quan và dự đoán nhịp tim là một dạng của bài toán này. Hình 6 minh họa cho kiến trúc của CNN-LSTM.



Hình 6. Kiến trúc CNN-LSTM


G. Convolutional long short-term memory (CONV-LSTM)

ConvLSTM [8] được đề xuất bởi Xingjian Shi và các cộng sự vào năm 2015. Kiến trúc ConvLSTM (Hình 7) là một biến thể của LSTM được mô tả ở trên, trong đó phép toán tích chập được sử dụng trong quá trình chuyển đổi đầu vào trạng thái và trạng thái sang trạng thái. Các phương trình trong ConvLSTM tại một thời điểm t như sau:

$$\begin{aligned} i_t &= \sigma(W_{xi} * x_t + W_{hi} * \mathcal{H}_{t-1} + W_{ci} \circ \mathcal{C}_{t-1} + b_i) \\ f_t &= \sigma(W_{xf} * x_t + W_{hf} * \mathcal{H}_{t-1} + W_{cf} \circ \mathcal{C}_{t-1} + b_f) \\ \mathcal{C}_t &= f_t \circ \mathcal{C}_{t-1} + i_t \circ \tanh(W_{xc} * x_t + W_{hc} * \mathcal{H}_{t-1} + b_c) \\ o_t &= \sigma(W_{xo} * x_t + W_{ho} * \mathcal{H}_{t-1} + W_{co} \circ \mathcal{C}_t + b_o) \\ \mathcal{H}_t &= o_t \circ \tanh(\mathcal{C}_t) \end{aligned}$$

trong đó: i_t : cổng đầu vào, f_t : cổng quên, o_t : cổng đầu ra, \mathcal{C}_t : trạng thái ô, \mathcal{H}_t : trạng thái ẩn

W : ma trận trọng số, b : bias, $*$: phép toán tích chập.



Hình 7. Kiến trúc CONV-LSTM

III. KẾT QUẢ THỰC NGHIỆM

A. Thiết bị Xiaomi Mi Smart Band 4

Xiaomi Mi Smart Band 4¹ là thế hệ vòng đeo tay thông minh của Xiaomi với khả năng theo dõi sức khỏe và vận động. Vòng tay MiBand 4 sẽ theo dõi các hoạt động thể chất như đi bộ, chạy, bơi lội và đạp xe. Thiết bị này còn có thể theo dõi được tốc độ, số bước chân, lượng calo tiêu thụ và nhịp tim. Chương trình được xây dựng bằng Python để kết nối với thiết bị đeo tay MiBand 4 thông qua Bluetooth để trích xuất các dữ liệu về nhịp tim, số bước chân, quãng đường đi được và số calo tiêu thụ.

B. Cài đặt chương trình

Chúng tôi đã tiến hành cài đặt chương trình thu thập dữ liệu từ thiết bị MiBand 4 và chương trình dự đoán nhịp tim bằng ngôn ngữ lập trình Python. Các thuật toán LSTM, GRU, Bi-LSTM, Bi-GRU, CNN-LSTM và CONV-LSTM được cài đặt bằng python và sử dụng thư viện Keras [8] và Tensorflow [9]. Tất cả kết quả nghiên cứu đều được thực nghiệm trên cùng hệ thống máy tính có kiến trúc như sau:

- CPU: Intel(R) Core i7-4790 CPU, 3,6 GHz, 4 cores.
- GPU: the Gigabyte GeForce RTX 2080Ti 11GB GDDR6, 4352 CUDA cores.
- RAM: 16 GB.
- Operating system: Linux Fedora 34.

C. Mô tả dữ liệu huấn luyện

Dữ liệu được thu thập được từ 4 người có đeo thiết bị MiBand 4 trong hoạt động hàng ngày. Bốn người gồm có 2 nam (48 tuổi và 13 tuổi) và 2 nữ (47 tuổi và 15 tuổi). Chương trình thu thập dữ liệu được kết nối với thiết bị MiBand 4 thông qua Bluetooth. Dữ liệu được thu thập theo từng giây lúc người dùng đeo thiết bị trong hoạt động sinh hoạt ban ngày, học tập, làm việc và ngủ. Thời điểm thu thập dữ liệu là trong khoảng thời gian giãn cách xã hội năm 2021 do bùng phát dịch Covid-19. Số lượng dữ liệu thu được thông qua thiết bị Mi Band 4 là 359.610 giây. Chúng tôi tiến hành tiền xử lý dữ liệu để đưa vào huấn luyện mô hình bằng cách sử dụng cửa sổ trượt 16 giây để chia dữ liệu. Kết quả của quá trình tiền xử lý dữ liệu thì chúng tôi thu được dữ liệu 359.594 mẫu có 16 giây. Tập dữ liệu được chia ra thành 2 tập gồm tập dữ liệu huấn luyện chiếm 67 % là 240.928 và 33 % là 118.666 làm tập dữ liệu kiểm thử. Chi tiết tập dữ liệu trong Bảng 1.

Bảng 1. Bảng dữ liệu nhịp tim

Tổng số dữ liệu	359.610 giây
Kích thước của sổ trượt	16 giây
Tổng số mẫu dữ liệu	359.594
Tập huấn luyện	240.928
Tập kiểm thử	118.666

D. Độ đo được sử dụng trong mô hình

Trung bình sai số tuyệt đối (Mean absolute error - MAE) được sử dụng để đánh giá hiệu suất của sáu mô hình học sâu như sau:

$$MAE = \frac{\sum_{i=1}^n |y_i - \hat{y}_i|}{n}$$

trong đó y_i : giá trị thực tế; \hat{y}_i : giá trị dự đoán; n : số lượng đánh giá.


E. Kết quả dự đoán nhịp tim

Bảng 2 và Hình 8 trình bày kết quả thực nghiệm dự đoán nhịp tim thu được từ 6 mô hình học sâu gồm GRU, LSTM, Bi-GRU, Bi-LSTM, CNN-LSTM và CONV-LSTM. Theo biểu đồ cho thấy tất cả mô hình có giá trị trung bình sai số tuyệt đối trong khoảng 3,4 đến 4,2, trong đó có 5 mô hình (GRU, LSTM, Bi-GRU, Bi-LSTM và CONV-LSTM) không có sự chênh lệch nhiều về giá trị sai số trung bình tuyệt đối trong khoảng từ 3,4 đến 3,6. Trong 6 mô hình thì mô hình Bi-GRU đạt giá trị MAE thấp nhất là 3.4535 trong khi CNN-LSTM đạt giá trị cao nhất là 4.1409.

Bảng 2. Kết quả của các mô hình học sâu cho dự đoán nhịp tim

Thuật toán	Mean absolute error (MAE)
LSTM	3.5785
GRU	3.5258
Bi-GRU	3.4535
Bi-LSTM	3.4766
CNN-LSTM	4.1409
CONV-LSTM	3.5999

¹ <https://www.mi.com/global/mi-smart-band-4/specs/>



Hình 8. Biểu đồ kết quả thực nghiệm

IV. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

Chúng tôi vừa trình bày hệ thống dự đoán nhịp tim dựa trên phương pháp học sâu. Sự đóng góp của chúng tôi là xây dựng chương trình để kết nối với thiết bị thông minh MiBand 4 thu thập dữ liệu gồm 359,594 mẫu và xây dựng hệ thống dự đoán nhịp tim dựa trên học sâu. Dữ liệu thu thập được từ người dùng gồm các thuộc tính sau: nhịp tim, số bước đi, calo tiêu thụ, quãng đường đi. Hệ thống dự đoán nhịp tim thông qua sáu mô hình mạng học sâu phổ biến như Gated recurrent units (GRU), Long short-term memory (LSTM), Bidirectional gated recurrent units (Bi-GRU), Bidirectional long short-term memory (Bi-LSTM), Convolutional neural network long short-term memory (CNN-LSTM), Convolutional long short-term memory (CONV-LSTM). Chúng tôi đã tiến hành thực nghiệm trên tập dữ liệu thu được và đánh giá mô hình bằng chỉ số MAE. Kết quả cho thấy rằng Bi-GRU có giá trị MAE tốt nhất (3.4535), ngược lại CNN-LSTM có giá trị kém nhất (4.1409). Kết quả thực nghiệm của 4 mô hình còn lại có giá trị MAE trong khoảng 3,4 đến 3,6. Thông qua kết quả thực nghiệm cho thấy mô hình Bi-GRU có hiệu quả tốt có thể áp dụng để dự đoán nhịp tim theo thời gian thực và đóng góp vào phát hiện bất thường về nhịp tim và điều trị kịp thời.

TÀI LIỆU THAM KHẢO

- [1] Alharbi, A., Alosaimi, W., Sahal, R. and Saleh, H., 2021. Real-time system prediction for heart rate using deep learning and stream processing platforms. Complexity, 2021.
- [2] Luo, M. and Wu, K., 2020. Heart rate prediction model based on neural network. In IOP Conference Series: Materials Science and Engineering (Vol. 715, No. 1, p. 012060). IOP Publishing.
- [3] McConville, R., Archer, G., Craddock, I., ter Horst, H., Piechocki, R., Pope, J. and Santos-Rodriguez, R., 2018. Online heart rate prediction using acceleration from a wrist worn wearable. arXiv preprint arXiv:1807.04667.
- [4] Staffini, A., Svensson, T., Chung, U.I. and Svensson, A.K., 2021. Heart rate modeling and prediction using autoregressive models and deep learning. Sensors, 22(1), p.34.
- [5] Hochreiter, S. and Schmidhuber, J., 1997. Long short-term memory. Neural Computation, 9(8), pp.1735-1780.
- [6] Cho, K., Van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H. and Bengio, Y., 2014. Learning phrase representations using RNN encoder-decoder for statistical machine translation. arXiv preprint arXiv:1406.1078.
- [7] Schuster, M. and Paliwal, K.K., 1997. Bidirectional recurrent neural networks. IEEE transactions on Signal Processing, 45(11), pp. 2673-2681.
- [8] Shi, X., Chen, Z., Wang, H., Yeung, D.Y., Wong, W.K. and Woo, W.C., 2015. Convolutional LSTM network: A machine learning approach for precipitation nowcasting. Advances in neural information processing systems, 28.
- [9] Abadi, M., Agarwal, A., Barham, P., Brevdo, E., Chen, Z., Citro, C., Corrado, G.S., Davis, A., Dean, J., Devin, M., Ghemawat, S., Goodfellow, I., Harp, A., Irving, G., Isard, M., Jia, Y., Jozefowicz, R., Kaiser, L., Kudlur, M., Levenberg, J., Mané, D., Monga, R., Moore, S., Murray, D., Olah, C., Schuster, M., Shlens, J., Steiner, B., Sutskever, I., Talwar, K., Tucker, P., Vanhoucke, V., Vasudevan, V., Viégas, F., Vinyals, O., Warden, P., Wattenberg, M., Wicke, M., Yu, Y., Zheng, X., "TensorFlow: Large-scale machine learning on heterogeneous systems", 2015, <https://www.tensorflow.org/>, software available from tensorflow.org
- [10] Biswas, D., Everson, L., Liu, M., Panwar, M., Verhoef, B.E., Patki, S., Kim, C.H., Acharyya, A., Van Hoof, C., Konijnenburg, M. and Van Helleputte, N., 2019. CorNET: Deep learning framework for PPG-based heart rate estimation and biometric identification in ambulant environment. IEEE transactions on biomedical circuits and systems, 13(2), pp. 282-291.
- [11] Shyam, A., Ravichandran, V., Preejith, S. P., Joseph, J. and Sivaprakasam, M., 2019. PPGnet: Deep network for device independent heart rate estimation from photoplethysmogram. In 2019 41st Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC) (pp. 1899-1902). IEEE.

- [12] Yuchi, M. and Jo, J., 2008. Heart rate prediction based on physical activity using feedforward neural network. In 2008 International Conference on Convergence and Hybrid Information Technology (pp. 344-350). IEEE.

HEART RATE PREDICTION BASED ON DEEP LEARNING

Do Thanh Nghi, Vo Tri Thuc

ABSTRACT: *In this paper, we propose the heart rate prediction system by deep learning. Cardiovascular disease is one of the dangerous diseases, causing patients to have a very high risk of death and leading to quick death. Therefore, monitoring and predicting heart rate plays an important role in early detection of abnormal heart function, timely treatment, and avoiding the risk of death. To tackle this problem, we developed a heart rate prediction system based on 6 popular deep learning models such as Gated recurrent units (GRU), Long short-term memory (LSTM), Bidirectional gated recurrent units (Bi)-GRU, Bidirectional long short-term memory (Bi-LSTM), Convolutional neural network long short-term memory (CNN-LSTM), Convolutional long short-term memory (CONV-LSTM). The system was built to connect to the MiBand 4 smartwatch that automatically collects heart rate and creates a training and test dataset of 359,594 samples. The experimental results show that all 6 models have the mean error value (MAE) in the range 3.4 to 4.2, in which the Bi-GRU model has the lowest MAE value (3.4535), followed by Bi-LSTM. is (3.4766).*